


Bias-Variance และ Learning Curves

การวิเคราะห์ความเอนเอียงและความแปรปรวนของแบบจำลองเชิงเส้น

รายวิชา Machine Learning · ภาคการศึกษาที่ 2569

จัดทำโดย: นาย วีรภัทร สาสิพล รหัสนักศึกษา: 6610301006

นาย พชร เพิ่มพูล รหัสนักศึกษา: 6610301008



โจทย์และเป้าหมายของงาน

งานนี้มุ่งวิเคราะห์ **Bias** และ **Variance** ของแบบจำลอง 3 ประเภท ด้วย 2 วิธีคำนวณ บนฟังก์ชันเป้าหมาย 2 รูปแบบ โดยสุ่มข้อมูลแบบเอกรูป 2 จุดในช่วง $[-1, 1]$ และใช้ **Normal Equation** เท่านั้น (ห้ามใช้ Gradient Descent)

3 แบบจำลองที่ศึกษา

- แบบจำลองค่าคงที่: $h(x) = b$
- แบบจำลองเชิงเส้น: $h(x) = ax + b$
- แบบจำลองเชิงเส้นผ่านจุดกำเนิด: $h(x) = ax$

2 ฟังก์ชันเป้าหมาย

- $\sin(\pi x)$ — ฟังก์ชันตรีโกณมิติไม่เป็นเชิงเส้น
- x^2 — ฟังก์ชันพหุนามกำลังสอง

2 วิธีคำนวณ

- **Analytical Method:** คำนวณค่าคาดหวัง $E[\cdot]$ ด้วยการอินทิเกรต
- **Simulation Method:** Monte Carlo สุ่มชุดข้อมูล 100,000 รอบแล้วหาค่าเฉลี่ย

ทฤษฎีพื้นฐาน: Bias, Variance และ E_{out}

กรอบทฤษฎี Bias-Variance Decomposition อธิบายองค์ประกอบของข้อผิดพลาดนอกชุดฝึก E_{out} ซึ่งแบ่งออกเป็น 3 ส่วนหลักที่มีความสัมพันธ์กันโดยตรง

Bias (ความเอนเอียง)



ค่าความคลาดเคลื่อนเฉลี่ยระหว่าง ค่าทำนายเฉลี่ยของแบบจำลอง กับ ฟังก์ชันเป้าหมายจริง
 $Bias(x) = \bar{g}(x) - f(x)$ ค่า Bias สูงหมายถึงแบบจำลองมีความยืดหยุ่นไม่เพียงพอที่จะประมาณ ฟังก์ชันจริงได้

Variance (ความแปรปรวน)

ค่าความผันผวนของแบบจำลองเมื่อ เปลี่ยนชุดข้อมูลฝึก $Var(x) = E_D[(g_D(x) - \bar{g}(x))^2]$ ค่า Variance สูงหมายถึงแบบจำลองไวต่อการเปลี่ยนแปลงข้อมูลฝึกมากเกินไป (Overfitting)

การแยกองค์ประกอบของ E_{out}

ข้อผิดพลาดนอกชุดฝึกสามารถแยกได้เป็น : $E_{out} = Bias^2 + Variance + \sigma^2$ โดยที่ σ^2 คือค่าความแปรปรวนของ Noise ในข้อมูล ซึ่งไม่สามารถลดได้ด้วยแบบจำลองใดๆ



เปรียบเทียบ 3 แบบจำลอง

ตารางด้านล่างสรุปคุณสมบัติหลักของแบบจำลองทั้ง 3 ประเภทที่ใช้ในการทดลอง ครอบคลุมสมการ จำนวนพารามิเตอร์ และระดับความซับซ้อนของแบบจำลอง

ชื่อแบบจำลอง	สมการ	พารามิเตอร์	ความซับซ้อน	ดีกรี
ค่าคงที่ (Constant)	$h(x) = b$	1 ตัว (b)	ต่ำสุด	0
เชิงเส้น (Linear)	$h(x) = ax + b$	2 ตัว (a, b)	ปานกลาง	1
เชิงเส้นผ่านจุดกำเนิด	$h(x) = ax$	1 ตัว (a)	ต่ำ–ปานกลาง	1

 **Code Snippet — ฟังก์ชัน fit (Python / NumPy):** ใช้ Normal Equation $w = (X^T X)^{-1} X^T y$ (ใช้ np.linalg.lstsq ซึ่งแก้ normal equation $X^T X w = X^T y$) สำหรับทุกแบบจำลอง โดยสร้างเมทริกซ์ design matrix X ให้สอดคล้องกับรูปแบบของแบบจำลองแต่ละประเภท

2 วิธีในการคำนวณ Bias และ Variance

Analytical Method

คำนวณค่าคาดหวัง $E[\cdot]$ โดยการ **อินทิเกรต**ทั่วทั้งช่วงข้อมูล $x \in [-1, 1]$ และทุกความเป็นไปได้ของชุดฝึก

- ได้ผลลัพธ์ที่ **แม่นยำสมบูรณ์** (Exact)
- ไม่ต้องสุ่มข้อมูล จึงไม่มี Sampling Error
- คำนวณได้ยากสำหรับปัญหาที่ซับซ้อน
- เหมาะสำหรับการพิสูจน์ทางทฤษฎี

Simulation Method (Monte Carlo)

สุ่มชุดข้อมูลฝึก $N = 2$ จุด จำนวน **100,000 รอบ** แล้วหาค่าเฉลี่ยของผลลัพธ์เพื่อประมาณค่าคาดหวัง


- ได้ผลลัพธ์ที่ **ประมาณค่า** (Approximate)
- มีความคลาดเคลื่อนจากการสุ่ม (Sampling Noise)
- นำไปใช้กับปัญหาทั่วไปได้ง่าย
- เหมาะสำหรับการทดลองเชิงปฏิบัติ

ทั้งสองวิธีควรให้ผลลัพธ์ที่ **ใกล้เคียงกันมาก** หากจำนวนรอบการจำลองมากพอ ซึ่งเป็นการตรวจสอบความถูกต้องของผลลัพธ์ซึ่งกันและกัน

ผลลัพธ์ข้อที่ 1: ฟังก์ชันเป้าหมาย $\sin(\pi x)$

ตารางค่า Bias และ Variance ของแบบจำลองทั้ง 3 ประเภท เปรียบเทียบระหว่างวิธี Analytical และ Simulation (100,000 รอบ) บนฟังก์ชัน $f(x) = \sin(\pi x)$ ช่วง $x \in [-1, 1]$

แบบจำลอง	Bias ² (Analytical)	Bias ² (Simulation)	Variance (Analytical)	Variance (Simulation)
ค่าคงที่ $h(x)=b$	0.5000	0.4995	0.2500	0.2494
เชิงเส้น $h(x)=ax+b$	0.2067	0.2063	1.6763	1.8830
ผ่านจุดกำเนิด $h(x)=ax$	0.2706	0.2732	0.2380	0.5072




📄 **กราฟ Bias-Variance — $\sin(\pi x)$:** [พื้นที่สำหรับแทรกรูปภาพเปรียบเทียบ E_{in} และ E_{out} ของทั้ง 3 แบบจำลอง แยกกรณีไม่มี Noise และมี Noise]

ผลลัพธ์ข้อที่ 2: ฟังก์ชันเป้าหมาย x^2

ตารางค่า Bias และ Variance ของแบบจำลองทั้ง 3 ประเภท เปรียบเทียบระหว่างวิธี Analytical และ Simulation (100,000 รอบ) บนฟังก์ชัน $f(x) = x^2$ ช่วง $x \in [-1, 1]$

แบบจำลอง	Bias ² (Analytical)	Bias ² (Simulation)	Variance (Analytical)	Variance (Simulation)
ค่าคงที่ $h(x)=b$	0.0889	0.0892	0.0444	0.0444
เชิงเส้น $h(x)=ax+b$	0.2000	0.2011	0.3333	0.3340
ผ่านจุดกำเนิด $h(x)=ax$	0.2000	0.2008	0.1149	0.1153



📌 **กราฟ Bias-Variance — x^2 :** [พื้นที่สำหรับแทรกรูปภาพเปรียบเทียบ E_{in} และ E_{out} ของทั้ง 3 แบบจำลอง แยกกรณีไม่มี Noise และมี Noise]


สรุป Bias-Variance Tradeoff

ความสัมพันธ์ระหว่างความซับซ้อนของแบบจำลองกับค่า Bias และ Variance แสดงให้เห็นถึง **Tradeoff** ที่ไม่สามารถหลีกเลี่ยงได้ในการเลือกแบบจำลอง

แบบจำลองง่าย (ค่าคงที่)

Bias: สูง — ไม่สามารถประมาณฟังก์ชันไม่เป็นเชิงเส้นได้ดี

Variance: ต่ำ — แบบจำลองไม่เปลี่ยนแปลงมากเมื่อเปลี่ยนชุดข้อมูล
เหมาะกับข้อมูลที่มี Noise สูงหรือข้อมูลน้อยมาก



แบบจำลองปานกลาง (เชิงเส้นผ่านจุดกำเนิด)


Bias: ปานกลาง — ยืดหยุ่นกว่าค่าคงที่ แต่ยังมีข้อจำกัด

Variance: ปานกลาง — ไวต่อข้อมูลน้อยกว่าแบบจำลองเชิงเส้นเต็มรูปแบบ
เป็นทางเลือกกลางที่สมดุลในหลายสถานการณ์

แบบจำลองซับซ้อน (เชิงเส้นเต็ม)

Bias: ต่ำ — ประมาณฟังก์ชันจริงได้ดีกว่า

Variance: สูง — โดยเฉพาะเมื่อ $N=2$ แบบจำลองไวต่อการเปลี่ยนแปลงข้อมูลมาก
เสี่ยง Overfitting เมื่อข้อมูลฝึกมีจำนวนน้อย



📄 **กราฟ Learning Curves เปรียบเทียบ:** [พื้นที่สำหรับแทรกรูปภาพ Learning Curves ของทั้ง 3 แบบจำลอง แยกกรณีไม่มี Noise และมี Noise แสดง E_{in} และ E_{out}]

เส้นโค้งการเรียนรู้ (Learning Curves)

องค์ประกอบของกราฟ

- **แกน X:** ขนาดชุดฝึก N (จำนวนจุดข้อมูล)
- **แกน Y:** ค่า E_{in} และ E_{out}
- **เส้นทึบ:** E_{out} (ข้อผิดพลาดนอกชุดฝึก)
- **เส้นประ:** E_{in} (ข้อผิดพลาดในชุดฝึก)

2 เงื่อนไขการทดลอง

- **ไม่มี Noise:** E_{out} ลดลงจนเข้าใกล้ 0 เมื่อ N เพิ่มขึ้น
- **มี Noise:** E_{out} ลดลงแต่ไม่สามารถต่ำกว่า σ^2 (Noise Floor)

สิ่งที่คาดหวังจาก Learning Curves

- เมื่อ N เพิ่มขึ้น E_{in} จะ **เพิ่มขึ้น** (แบบจำลองเห็นข้อมูลมากขึ้น)
- เมื่อ N เพิ่มขึ้น E_{out} จะ **ลดลง** (แบบจำลอง generalize ได้ดีขึ้น)
- ช่องว่างระหว่าง E_{in} และ E_{out} บ่งชี้ระดับ **Variance**
- แบบจำลองซับซ้อนจะมีช่องว่างกว้างกว่าเมื่อ N น้อย

📄 **กราฟ Learning Curves เปรียบเทียบ:** [พื้นที่สำหรับแทรกรูปกราฟ Learning Curves ของทั้ง 3 แบบจำลอง แยกกรณีไม่มี Noise และมี Noise แสดง E_{in} และ E_{out}]

ข้อสังเกตสำคัญจากการทดลอง

1

E_{out} ระเบิดสูงมากเมื่อมี Noise ที่ $N=2$

แบบจำลองเชิงเส้น $h(x) = ax + b$ เมื่อฝึกด้วยข้อมูลเพียง 2 จุดที่มี Noise ค่า E_{out} จะ **สูงผิดปกติ** เนื่องจาก Variance สูงมากเมื่อข้อมูลน้อย แบบจำลองพยายาม Fit ข้อมูลที่มี Noise จนเกิด Overfitting รุนแรง ทำให้การทำนายบนข้อมูลใหม่น่าเชื่อถือได้น้อยมาก

2

Noise Floor = σ^2 คือขีดจำกัดล่างของ Error

เมื่อข้อมูลมี Noise ค่า E_{out} ที่ดีที่สุดที่เป็นไปได้จะไม่ต่ำกว่า σ^2 (ความแปรปรวนของ Noise) ไม่ว่าแบบจำลองจะซับซ้อนเพียงใดก็ตาม นี่คือ **Irreducible Error** ที่ไม่สามารถกำจัดได้ด้วยการปรับปรุงแบบจำลอง เป็นข้อจำกัดพื้นฐานของปัญหาที่มีข้อมูลไม่สมบูรณ์

✔ **บทสรุป:** การเข้าใจ Bias-Variance Tradeoff และ Learning Curves ช่วยให้นักพัฒนาเลือกความซับซ้อนของแบบจำลองได้เหมาะสมกับปริมาณและคุณภาพของข้อมูลที่มีอยู่